


统计学分析

显著性 分析和 相关性 分析

统计学

二组类问题（二分类）



相关性分析



正态性检验

Yes 皮尔逊相关系数

No 斯皮尔曼等级相关系数

假设检验

- 原假设[H_0]: 效应没有出现
 - 备择假设[H_a]: (非此即彼)
 - 显著性水平: α (1类错误) **【0.05、0.01、0.001】**
(统计者愿意接收1类错误的比率)
 - P-值: 由于偶然因素或随机抽样误差致使样本统计量取某值的概率
-

正态性检验

- Kolmogorov-Smirnov检验 (K-S检验) : $n > 50$
(计算经验分布与理论分布的最大差异, 适用于大样本, 但对小样本敏感性较低。)

-
- Shapiro-Wilk检验: $7 < n < 2000$
(最有效的小样本正态性检验方法)



齐方差检验

- Levene检验：没有正态性要求
-



Student's t 检验

- 满足条件：正态性和方差齐性
 - 应用：确定两个组之间的平均差异是否显著不同
-

- 独立样本T检验：比较两个不相关组的平均值。
- 配对样本T检验：比较同一组在不同时间点的平均值。
- 单样本T检验：将特定组的平均值与已知平均值进行比较。



Welch's t 检验

- 满足条件：正态性、样本独立性、样本量($n > 30$)
 - 应用：专门用于处理两组样本方差不相等的情况
-



曼-惠特尼U检验

- **应用**：用于评估两个独立组之间差异的检验，如果你的数据不符合正态分布。
(当数据**不符合正态性假设**时，它是**T检验的替代方法**。)
(曼-惠特尼U统计量是基于合并数据集中数据的秩计算的。)
-



皮尔逊相关系数

- **满足条件**：连续数据，且数据服从正态分布或接近正态分布
 - **应用**：评估两个连续变量之间的线性关联。
(它产生一个介于-1和1之间的值，表示关联的强度和方向。)
-



斯皮尔曼等级相关系数

- **满足条件**：不需要满足正态分布，只需满足单调关系
(连续变量或定序数据)
 - **应用**：用于衡量两个变量之间的单调关系，即变量的变化趋势是否一致。
(其值范围同样为 $[-1, 1]$ ，但对数据的分布要求较低。)
-



卡方检验

- **应用**：确定两种数据类型之间是否存在强烈的关联性

-
- 独立性卡方检验：旨在确定两个分类变量是否独立。
 - 拟合优度卡方检验：旨在确定样本分布是否与总体分布相匹配。

多组类问题（多分类）

方差分析 (ANOVA)

- **满足条件**：连续型、可量化、近似正态分布(正态性)
- **应用**：用于比较三组及以上数据均值是否存在显著差异

-
- 一元ANOVA：比较具有三个或更多水平（组）的一个自变量的平均值。
 - 二元ANOVA：考虑两个自变量比较平均值。
 - 重复测量ANOVA：当所有组都使用相同的受试者时使用。

Kruskal - Wallis H检验

- **满足条件**：适用于**非正态**分布数据(非参数检验)
 - **应用**：
 - **原理**：将所有观测值按照大小排序后赋予秩次，然后计算各组的平均秩次。
-

特征 分析

机器学习

机器学习评价指标

- 准确率（Accuracy）
- 精确率（Precision）
- 召回率（Recall）
- F1 分数（调和平均）

-
- ROC 曲线
 - AUC（ROC 曲线下面积）

		Actual	
Predicted		Positive	Negative
	Positive	True Positive (TP)	False Positive (FP)
	Negative	False Negative (FN)	True Negative (TN)

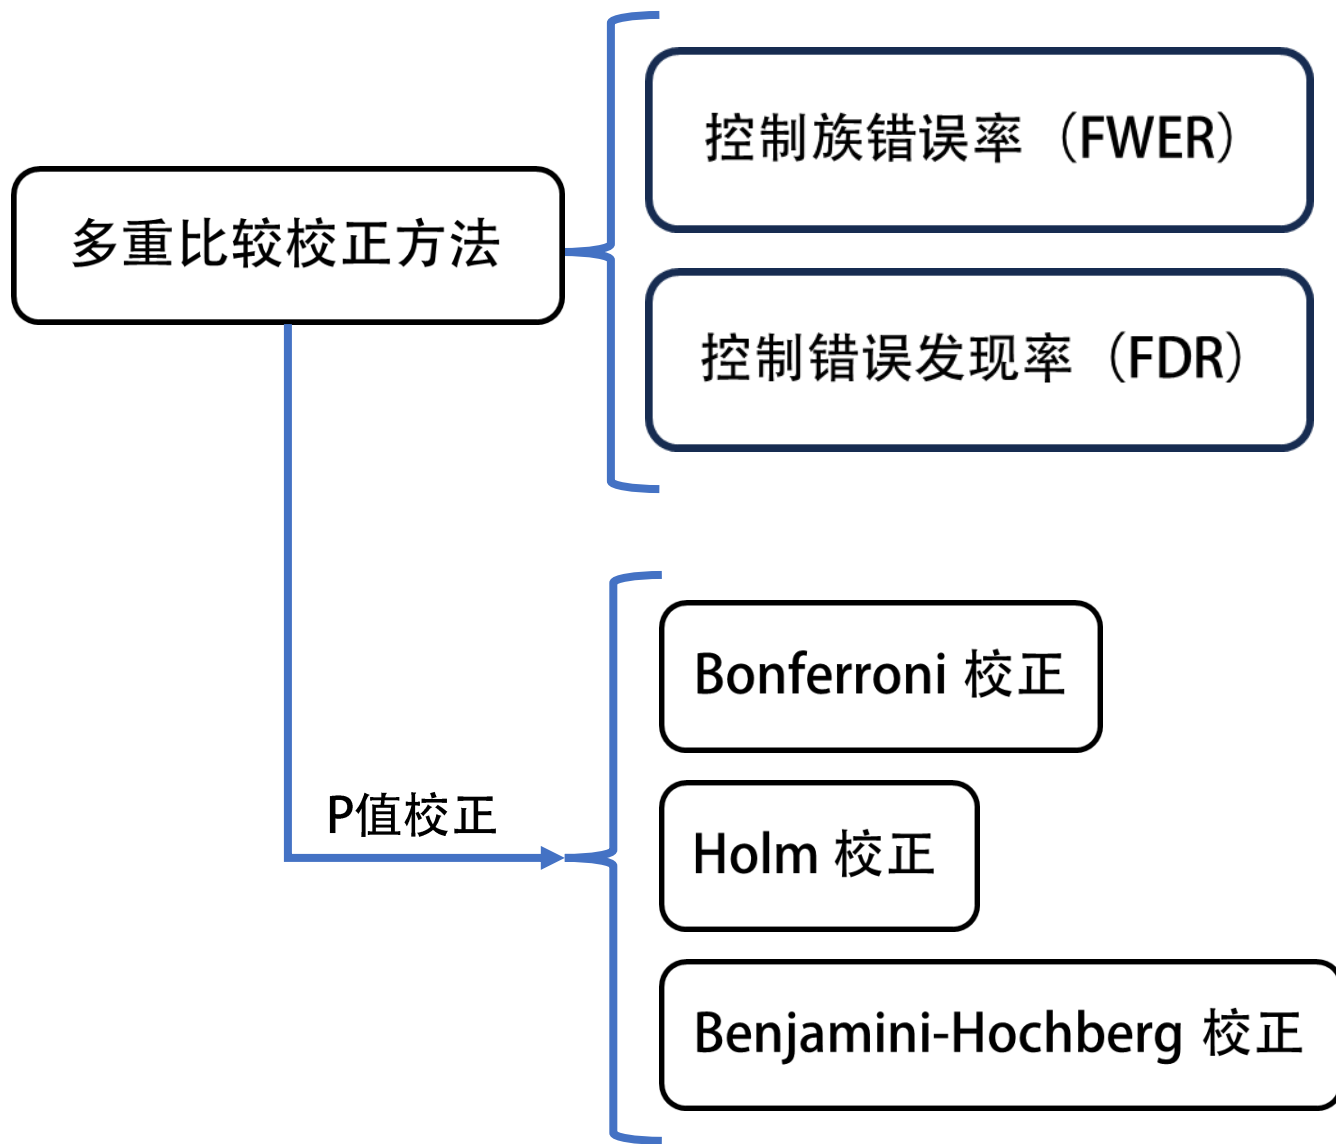
$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

P值校正



Bonferroni 校正

- 控制 FWER（至少出现一次假阳性的概率）
- 新阈值： $\alpha / m = 0.05 / m$ （静态阈值）
- 容易漏掉真实差异

Holm 校正

- 控制 FWER（动态、逐步）
- 先将 P 值从小到大排序，然后依次检查：

$$P_i \leq \alpha / (m - i + 1)$$

- 一旦出现不显著，后面所有的检验自动停止，均判定为不显著
- 比 Bonferroni 更容易发现真实差异

Benjamini-Hochberg 校正

- 控制 “错误发现率 ” (FDR, False Discovery Rate)
- 步骤:
 1. FDR 水平 $q = 0.05$ （你接受所有显著结果中，假阳性比例不超过 5%）
 2. 将所有 P 值从小到大排序： $P_1 \leq P_2 \leq \dots \leq P_n$ 。
 3. 从最大的 P 值 ($i=n$) 开始，向前寻找最大的 i ，使得 $P_i \leq (i / m) \times q$ 。
 4. 一旦找到这个 “最大显著索引” k ，就宣布 $P_1, P_2, \dots, P_k$ 全部显著。